

Relatório de Implementação e Avaliação: Otimização de LLMs Médicos via RAG e MLOps (Equipe 5 MED)

1. Cabeçalho e Resumo Executivo

Este relatório detalha o desenvolvimento e a validação técnica de um sistema de suporte à decisão clínica, concebido no contexto da disciplina "**Tópicos Avançados em Engenharia de Software e Sistemas de Informação I**". O projeto fundamenta-se na premissa de que a autonomia tecnológica e a soberania de dados são pilares inegociáveis para a transformação digital da saúde, exigindo que o processamento de informações sensíveis ocorra em infraestrutura local e auditável.

Resumo Executivo

A implementação de Inteligência Artificial em ambientes hospitalares enfrenta um paradoxo crítico: a necessidade imperativa de processamento offline para garantir a privacidade dos dados e a conformidade ética, contraposta à tendência de alucinação e obsolescência de modelos compactos operando exclusivamente em "memória pura". Durante o benchmark inicial, modelos locais sem suporte externo demonstraram falhas severas em posologia e aderência a protocolos atualizados, representando um risco inaceitável à segurança do paciente e ao *Standard of Care*.

A solução proposta utiliza uma arquitetura de Geração Aumentada por Recuperação (RAG) para desacoplar a capacidade linguística do modelo do seu conhecimento estático. Através da integração de um banco de vetores dinâmico alimentado por diretrizes de alta autoridade, o sistema eliminou lacunas informacionais e reduziu drasticamente as omissões terapêuticas. Os resultados quantitativos, validados por um framework de Juiz-IA, demonstram que a tríade MLOps — composta por recuperação de evidências, modelos locais e auditoria resiliente — é o caminho mais seguro para a viabilidade industrial da IA médica.

- **Projeto:** Otimização de LLMs Médicos via RAG e MLOps
- **Equipe:** Equipe 5 MED
- **Integrante:** Sergio Santana dos Santos

A transição de modelos experimentais para sistemas de suporte clínico de alta fidelidade exige uma rearquitetura do fluxo de dados que priorize a recuperação semântica sobre a mera probabilidade estatística.

2. Introdução e Contextualização do Problema

A conformidade com as normas de privacidade e a ética médica impõe que o tratamento de dados de saúde seja realizado, prioritariamente, em ambiente local. A dependência excessiva de APIs de nuvem para inferência clínica introduz riscos de vazamento de informações sensíveis e vulnerabilidades de disponibilidade que podem comprometer a continuidade do cuidado.

Contudo, modelos de linguagem compactos, como o **Llama-3 8B**, **Mistral 7B** e **Phi-3**, possuem limitações intrínsecas quando operam sem suporte externo:

- **Obsolescência do Conhecimento:** O treinamento estático não acompanha a evolução veloz de diretrizes clínicas.
- **Alucinações Posológicas:** A "memória pura" falha ao precisar dosagens e contraindicações específicas.
- **Instabilidade em Casos Complexos:** Modelos compactos priorizam fluidez linguística em detrimento da precisão diagnóstica.
- **Desvio Clínico (Data Drift):** Sem um ciclo de atualização via MLOps, as respostas degradam conforme novos protocolos são publicados.

Para validar a superação desses desafios, utilizamos dados de teste baseados em questões abertas e simulados do **USMLE (United States Medical Licensing Examination)**, garantindo um nível de rigor compatível com a prática médica global. A resolução dessas falhas exigiu uma infraestrutura de MLOps robusta para orquestrar o fluxo de recuperação e geração de respostas.

3. Metodologia: Arquitetura MLOps e Geração Aumentada por Recuperação (RAG)

A arquitetura do sistema foi desenhada para integrar conhecimento dinâmico via **Atividade 03**, transformando o LLM em um motor de raciocínio que consulta uma base de "verdade terrestre" antes de emitir qualquer parecer.

A implementação utilizou o **ChromaDB** como banco de vetores. Foram aplicadas técnicas de *embedding* semântico para indexar diretrizes da **AHA 2023 (American Heart Association)** e **ADA 2024 (American Diabetes Association)**. Para garantir a integridade clínica, utilizamos uma estratégia de **chunking semântico**, assegurando que recomendações de dosagem e critérios diagnósticos não fossem fragmentados, mantendo o contexto coeso para o recuperador.

Estrutura do Ecossistema MLOps

Componente	Função no Ecossistema MLOps
ChromaDB (Vector Store)	Armazenamento de alta performance e busca de similaridade via <i>embeddings</i> médicos.
Base de Conhecimento	Repositório de diretrizes curadas (AHA 2023, ADA 2024) para evitar alucinações.
Orquestração Local	Scripts de controle de fluxo e limpeza de dados (pre-processing) para entrada no modelo.
Barramento de Auditoria	Logs de inferência e rastreabilidade para monitoramento de segurança e ética.

Esta arquitetura robusta requer um método de avaliação igualmente sofisticado, substituindo métricas linguísticas simples por um framework de julgamento clínico.

4. Metodologia de Avaliação: Framework LLM-as-a-Judge

No domínio médico, métricas tradicionais como ROUGE ou BLEU são irrelevantes. A precisão semântica e a segurança clínica superam a simples sobreposição de palavras; um erro de uma casa decimal na dosagem de um fármaco pode ser fatal, independentemente da fluidez do texto.

Implementamos o framework **LLM-as-a-Judge**, utilizando o modelo **Llama-3.3-70B** via API **Groq**. A escolha justifica-se pelo equilíbrio entre latência ultrabaixa e alta capacidade de raciocínio lógico necessário para auditar condutas médicas. Para garantir a resiliência (MLOps Resilience), estabelecemos um mecanismo de **Fallback** para o **Gemini 1.5 Flash**. Esse sistema de redundância assegura que a auditoria de resultados seja ininterrupta, mesmo diante de instabilidades de conectividade ou limites de cota na API principal.

O Juiz-IA atua como um auditor de conformidade, avaliando se a resposta gerada pelo modelo local está em estrita consonância com o *Standard of Care* e sinalizando erros críticos de omissão ou prescrição.

5. Análise de Resultados Quantitativos

A análise quantitativa é fundamental para validar a transição tecnológica em sistemas críticos. Com base no processamento dos arquivos `dados_completos_abertas.csv` e `dados_completos_mcq.csv`, os resultados foram estratificados:

Performance Comparativa:

- **Antes do RAG (Baseline):** Os modelos operando em "memória pura" apresentaram inconsistência severa. Em casos de posologia farmacológica e diagnósticos específicos, as notas médias atribuídas pelo Juiz-IA situaram-se entre **1.0 e 3.0**. A taxa de acerto em questões de múltipla escolha (MCQs) foi de **[DADO]%**, revelando lacunas em conhecimentos não presentes no treinamento base.
- **Com RAG (Otimizado):** Houve uma elevação linear na qualidade das respostas, com notas médias subindo para o intervalo de **4.0 a 5.0**. O modelo Llama-3, por exemplo, atingiu nota máxima em casos de manejo de hipertensão em diabéticos após acessar a base da ADA 2024. A taxa de acerto em MCQs subiu para **[DADO]%**.

A aplicação da **Correlação de Spearman** confirmou uma relação estatística forte entre a assertividade na recuperação de documentos e a nota final. Isso demonstra que a melhoria na qualidade do raciocínio clínico não é aleatória, mas diretamente proporcional à capacidade do sistema de contextualizar o modelo com evidências dinâmicas.

6. Análise de Resultados Qualitativos (Estudos de Caso)

A análise qualitativa, extraída do arquivo `insights_sergio_para_aistudio.csv`, identifica falhas de segurança que métricas agregadas poderiam ocultar.

Estudo de Caso 01: Correção de Posologia (Ibuprofeno)

O modelo Mistral falhou ao limitar a dose máxima de Ibuprofeno, o que poderia levar a um manejo inadequado da dor.

- **Cenário Original:** O modelo indicou dose máxima de 600 mg.
- **Justificativa do Juiz:**
- **Impacto do RAG:** A recuperação da diretriz farmacológica no banco de vetores corrigiu a subdosagem, alinhando a resposta ao limite de segurança de 3200 mg/dia.

Estudo de Caso 02: Diagnóstico Diferencial (Disúria em Homens Jovens)

O modelo local tendeu a simplificar o diagnóstico como uma Infecção do Trato Urinário (ITU) comum, ignorando o perfil epidemiológico.

- **Cenário Original:** O modelo sugeriu ITU como causa principal.
- **Justificativa do Juiz:**
- **Impacto do RAG:** A inclusão de protocolos de IST no ChromaDB permitiu que o modelo priorizasse a etiologia correta, mitigando o risco de tratamento ineficaz e complicações como epididimite.

7. Conclusão e Viabilidade Industrial

O projeto comprova que a tríade "**Modelos Locais + RAG + Auditoria em Nuvem**" oferece o equilíbrio ideal entre privacidade inegociável e acurácia clínica. A arquitetura desenvolvida transcende o ambiente acadêmico, apresentando-se como uma solução pronta para a indústria.

Pilares para Implantação Hospitalar:

1. **Segurança e Privacidade:** Processamento local integral, eliminando riscos de vazamento de dados sensíveis e garantindo conformidade com a LGPD e o sigilo médico.
2. **Escalabilidade e Integração:** O sistema é desenhado para operar em contêineres (**Docker/Kubernetes**) e integrar-se a Prontuários Eletrônicos do Paciente (PEP) via APIs modernas (**FHIR**), permitindo consultas ao histórico do paciente em milissegundos.
3. **Monitoramento e Auditoria:** O uso de dashboards em **Streamlit** permite a supervisão contínua da performance do sistema e a detecção de *Data Drift*, garantindo que a base de conhecimento (AHA/ADA) seja atualizada sem necessidade de re-treinamento do modelo.

Em última análise, o RAG transforma modelos de linguagem de "geradores de texto" em sistemas de suporte clínico de alta fidelidade, proporcionando uma ferramenta segura, escalável e cientificamente embasada para a assistência médica inteligente.